

Projeto – Feminicídio – A ação dos dados como um fato social.

Alexandre Machado Ferreira e Silva, Guilherme Henrique Souza, Marcus de Oliveira dos Santos, Pedro Henrique Levinski, Sara Belintani, Thiago Ximenes Naves, Orientador Gleisson Albergaria Amaral.

PUC Minas

Curso de Tecnologia em Banco de Dados

alexandre.silva.1551909@sga.pucminas.br,

guilherme.souza.1456357@sga.pucminas.br,

marcus.santos.441114@sga.pucminas.br,

pedrofilo@gmail.com,

sara.belintani.contato@gmail.com,

thiago.naves@sga.pucminas.br.

6. Limpeza e Transformação (Etapa 4)

Após a etapa de captura dos dados, os conjuntos provenientes das bases originais foram inseridos em um banco de dados relacional utilizando o PostgreSQL. Entretanto, os dados ainda se encontravam em formato bruto, contendo atributos redundantes, nomenclaturas técnicas e inconsistências que dificultavam a realização de análises estatísticas e a construção de visualizações analíticas no Power BI.

Inicialmente, as bases utilizadas no projeto estavam organizadas nas seguintes tabelas brutas:

- raw_sim_causas_externas;
- raw_sim_causas_externas_preliminar;
- pns_violencia_2013;
- pns_violencia_2019;
- feminicidio_prelim;
- feminicidio_serie_historica.

Essas tabelas possuíam características transacionais e operacionais, contendo grande quantidade de colunas e informações não relevantes para o contexto analítico do projeto. Dessa forma, foi necessário realizar um processo de limpeza, padronização e transformação dos dados, visando melhorar a qualidade das informações e otimizar o desempenho das consultas analíticas.

O processo de carga e transformação contemplou bases com elevado volume de dados, totalizando mais de dois milhões de registros distribuídos entre diferentes arquivos e estruturas. Em função dessa volumetria, tornou-se necessária a adoção de estratégias voltadas à otimização do armazenamento e do desempenho das consultas analíticas realizadas posteriormente.

Durante o tratamento dos dados foram executadas operações de:

- remoção de colunas irrelevantes;
- padronização de nomenclaturas;
- adequação de tipos de dados;
- tratamento de valores nulos;
- normalização de datas e horários;
- consolidação de informações geográficas;
- criação de métricas agregadas;
- separação entre atributos descritivos e quantitativos.

Os valores nulos ou inconsistentes foram tratados por meio da substituição por valores padronizados, como “Não Informado”, evitando falhas em consultas e agregações estatísticas. Também foram realizadas conversões de tipos de dados, especialmente em campos temporais, permitindo a correta manipulação de datas, horários e períodos de análise.

Com o objetivo de melhorar a organização dos dados e reduzir redundâncias, foi adotado um modelo dimensional baseado na abordagem Star Schema (esquema estrela). Essa modelagem foi escolhida por facilitar consultas analíticas, melhorar a performance no processamento de relatórios e simplificar a integração com ferramentas de Business Intelligence.

A modelagem dimensional foi implementada diretamente no banco de dados, reduzindo a necessidade de transformações adicionais no Power BI. Essa abordagem permitiu diminuir o custo computacional durante a geração dos relatórios, além de proporcionar maior organização lógica das informações e melhor desempenho nas consultas.

O modelo dimensional foi estruturado em tabelas fato e tabelas dimensão.

As tabelas dimensão foram responsáveis pelo armazenamento de informações descritivas e contextuais:

- dim_calendario;
- dim_geografia;
- dim_perfil_demografico.

A dimensão calendário foi criada para possibilitar análises temporais por ano, mês, trimestre e dia da semana. A dimensão geográfica concentrou informações territoriais, como município, estado, região e coordenadas geográficas. Já a dimensão demográfica reuniu atributos relacionados ao perfil das vítimas, incluindo sexo, raça e estado civil.

As tabelas fato foram responsáveis pelo armazenamento dos eventos e indicadores quantitativos analisados:

- fato_feminicidio_detalhada;
- fato_feminicidio_resumida;
- fato_pesquisa_pns.

A tabela fato_feminicidio_detalhada armazena os registros completos relacionados aos casos de feminicídio, contendo informações sobre data do óbito, localidade, causa e características das vítimas. A tabela fato_feminicidio_resumida foi criada para análises agregadas, reduzindo o volume de processamento em consultas de alto nível. Já a tabela fato_pesquisa_pns reúne os indicadores provenientes da Pesquisa Nacional de Saúde, permitindo análises relacionadas à violência física, psicológica e sexual.

Como estratégia de otimização analítica, a tabela fato_feminicidio_resumida foi desenvolvida para armazenar informações previamente agregadas, reduzindo o volume de processamento necessário em consultas estatísticas e indicadores gerais. Já a tabela fato_feminicidio_detalhada foi mantida com maior granularidade, permitindo análises específicas e detalhadas sob demanda.

Além disso, foi utilizada a tabela auxiliar geo_macroregiao, responsável pelo enriquecimento das informações geográficas, incluindo macrorregiões de saúde, latitude e longitude dos municípios.

Como estratégia de desempenho, foram implementados índices nas principais tabelas e colunas utilizadas em filtros e relacionamentos, visando otimizar consultas SQL e melhorar a performance das integrações com o Power BI. Também foi adotada uma estratégia híbrida de armazenamento,

combinando tabelas em modo Import e DirectQuery, permitindo equilíbrio entre velocidade de carregamento e detalhamento analítico.

A Figura 1 apresenta o modelo dimensional final desenvolvido para o projeto, contendo as tabelas fato, tabelas dimensão e seus respectivos relacionamentos. O posicionamento das tabelas no diagrama seguiu os princípios da modelagem dimensional em esquema estrela, no qual as tabelas dimensão permanecem centralizadas em torno das tabelas fato. Essa organização facilita a identificação dos relacionamentos, melhora a legibilidade do modelo e representa de forma mais clara os processos analíticos utilizados no ambiente de Business Intelligence.

Além disso, o processo de transformação dos dados foi inspirado em conceitos modernos de engenharia de dados, utilizando uma abordagem progressiva de refinamento das informações até a consolidação do modelo analítico final. Essa estratégia contribuiu para maior padronização, consistência e reutilização dos dados ao longo do projeto.

O processo de limpeza e transformação permitiu maior padronização dos dados, redução de redundâncias e melhor desempenho nas consultas analíticas. Como resultado, o banco de dados tornou-se adequado para utilização em ferramentas de Business Intelligence, possibilitando a construção de dashboards e análises estatísticas de forma eficiente e organizada.



Figura 1 – Modelo dimensional do banco de dados em esquema estrela (Star Schema).

O posicionamento das tabelas no diagrama seguiu os princípios da modelagem dimensional em esquema estrela, no qual as tabelas dimensão permanecem centralizadas em torno das tabelas fato. Essa organização facilita a identificação dos relacionamentos, melhora a legibilidade do modelo e representa de forma mais clara os processos analíticos utilizados no ambiente de Business Intelligence.

